Nama : Citra Ardhia Intan N.
NIM : 23031554129
Kelas : Sains Data 2023 E

INTRERPRETASI HASIL SOAL UTS

2.1 Wrangling dan EDA

1 Periode training dan testing

Data RetailRocket dibagi menjadi P1 (training) 17 Mei–5 Agustus 2015 dan P2 (testing) 6–26 Agustus 2015, berdasarkan timestamp UTC.

2 Filter timestamp dan keluaran CSV

Dari 2.756.101 baris awal, hasil filter adalah P1 = 1.717.177 baris dan P2 = 370.736 baris. Hasil disimpan sebagai output/retailrocket_p1_training.csv dan output/retailrocket_p2_testing.csv.

3 Komposisi subgraph dan Cypher

Simpul	Jumlah	Relasi	Jumlah
Visitor	880.538	VIEWED	7.585.894
Item	191.676	ADDED_TO_CART	193.672
Total node	1.072.214	BOUGHT	64.142
		Total relasi	7.843.708

```
MATCH (n) WHERE n:Visitor OR n:Item
UNWIND labels(n) AS jenis_simpul RETURN jenis_simpul, count(*) AS jumlah;
MATCH (v:Visitor)-[r]->(i:Item)
RETURN type(r) AS jenis_relasi, count(r) AS jumlah;
```

Query pertama menghitung node menurut label; query kedua menghitung relasi menurut jenis. Keduanya dijalankan dengan Python API melalui session.run().

4 VSM Visitor

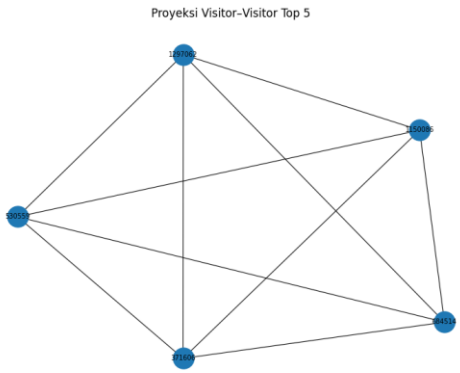
Matriks Visitor × Item berukuran (880.538, 191.676), berisi 1.335.468 nilai tidak nol, sparsity 99,999209%, dan rata-rata 1,52 item per Visitor. Bobot interaksi: VIEWED=1, ADDED_TO_CART=2, BOUGHT=3. Proyeksi NetworkX sampel menghasilkan 5 node, 10 edge, density 1,0.

5 VSM Item

Matriks Item × Visitor berukuran (191.676, 880.538), berisi 1.335.468 nilai tidak nol dengan sparsity 99,999209%; rata-rata 6,97 Visitor per Item. VSM Item adalah transpose VSM Visitor. Plot NetworkX Item–Item tidak ditampilkan dalam notebook.

6 Proyeksi yang lebih efektif/efisien

Keduanya setara dalam penyimpanan matriks sparse karena jumlah elemen nonzero sama. Proyeksi Visitor–Visitor dipakai untuk User-Based KNN, sedangkan Item–Item cocok untuk menemukan kemiripan produk dan memiliki lebih sedikit objek (191.676 dibanding 880.538).



Graf NetworkX Visitor–Visitor pada sampel lima pengguna (output notebook).

2.1 Similarity dan Graf

7 Cosine similarity: lima Visitor terdekat

Similarity dihitung dari normalisasi vektor interaksi dengan cosine similarity. Untuk Visitor acuan 716411, hasil lima teratas adalah:

Visitor mirip	Similarity	Visitor mirip	Similarity
416428	1,000000	1383374	1,000000
1105711	0,707107	416974	0,408248
799282	0,316228	—	—

```
MATCH (u:Visitor {visitorId: $user_id})-[r:SIMILAR_TO]->(v:Visitor)
RETURN v.visitorId AS visitor_mirip, r.similarity AS similarity
ORDER BY similarity DESC LIMIT 5;
```

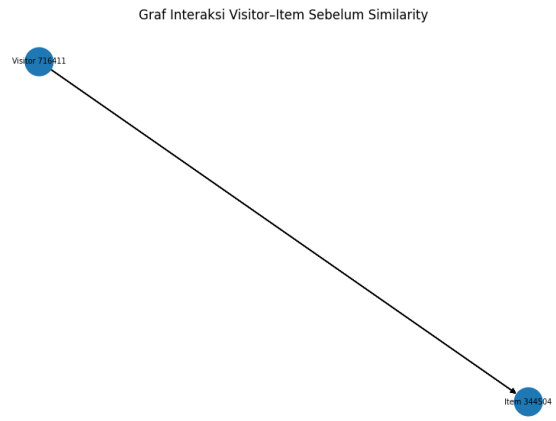
Nilai disimpan ke relasi SIMILAR_TO menggunakan UNWIND $rows, MERGE, dan SET r.similarity. Jumlah hubungan tersebut berubah dari 0 menjadi 5 untuk Visitor 716411.

```
UNWIND $rows AS row
MATCH (u:Visitor {visitorId: row.source_user})
MATCH (v:Visitor {visitorId: row.target_user})
MERGE (u)-[r:SIMILAR_TO]->(v)
SET r.similarity = row.similarity, r.method = 'cosine',
    r.training_period = 'P1';
```

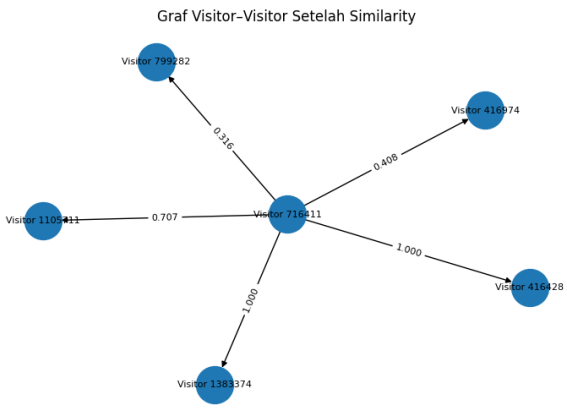
8 Graf sebelum dan sesudah similarity

Sebelum: Visitor 716411 terhubung ke Item 344504 melalui VIEWED (output menampilkan lima relasi berulang). Sesudah: Visitor tersebut terhubung dengan lima Visitor lain melalui SIMILAR_TO, dengan skor similarity pada setiap edge.

```
// Sebelum
MATCH (u:Visitor {visitorId: 716411})-[r]->(i:Item) RETURN u,r,i LIMIT 30;
// Sesudah
MATCH (u:Visitor {visitorId: 716411})-[r:SIMILAR_TO]->(v:Visitor)
RETURN u,r,v LIMIT 5;
```



Sebelum: Visitor–Item



Sesudah: Visitor–Visitor

2.2 Analytics

1a Pemilihan acak dan skrip KNN

Menggunakan seed=42 dan k=5. Pemilihan acak awal menghasilkan Visitor 124145. Pada tahap rekomendasi, kandidat user diperiksa lagi agar memiliki ≥5 tetangga dan ≥3 item baru; hasil akhirnya Visitor 716411.

```
rng = np.random.default_rng(42)
for uid in rng.choice(eligible_users, size=min(200, len(eligible_users)), replace=False):
    idx = user_pos[int(uid)]
    sim = np.asarray((Xn @ Xn.getrow(idx).T).toarray()).ravel()
    sim[idx] = 0
    valid = np.flatnonzero(sim > 0)
    if len(valid) < 5: continue
    tetangga = valid[np.argsort(sim[valid])[::-1][:5]]
    skor = np.asarray(X[tetangga].T @ sim[tetangga]).ravel()
    skor[X.getrow(idx).indices] = 0
    kandidat = np.flatnonzero(skor > 0)
    if len(kandidat) >= 3:
        target_user = int(uid)
        top5 = kandidat[np.argsort(skor[kandidat])[::-1][:5]]
        break
rekomendasi_item = item_ids[top5]
```

1b Tiga item yang diiklankan (k=5)

Peringkat	Item ID	Skor
1	149679	3,535534
2	437694	3,265986
3	250379	1,632993

Sebanyak 12 kandidat item baru ditemukan. Tiga item di atas dipilih karena mempunyai skor rekomendasi tertinggi dari lima tetangga terdekat.

2a–2b Hit@5 dan NDCG@5

Lima rekomendasi adalah 149679, 437694, 250379, 453618, dan 344817; semuanya memiliki relevansi 0 pada P2. Ada dua item relevan di P2, tetapi tidak satu pun muncul pada Top-5.

Metrik	Hasil	Keterangan
Hit@5	0	Tidak ada item relevan di Top-5
DCG@5	0	Seluruh relevansi = 0
IDCG@5	1,63093	Dua item relevan ideal
NDCG@5	0	0 ÷ 1,63093 = 0

Kesimpulan: Pada Visitor 716411, model menghasilkan rekomendasi tetapi belum berhasil menemukan item yang relevan menurut data testing.